

**РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА**  
***К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ***  
***НА ТЕМУ:***

|                  |                     |                 |                                |
|------------------|---------------------|-----------------|--------------------------------|
| Студент          | ИУ5-61Б<br>(группа) | (подпись, дата) | Князев А.М.<br>(И.О. Фамилия)  |
| Руководитель НИР |                     | (подпись, дата) | Гапанюк Ю.Е.<br>(И.О. Фамилия) |

2026 z.

Министерство науки и высшего образования Российской Федерации  
Федеральное государственное автономное образовательное учреждение  
высшего образования  
«Московский государственный технический университет имени Н.Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ

Заведующий кафедрой ИУ5

(индекс)

В.И. Терехов

(И.О. Фамилия)

(подпись)

(дата)

**ЗАДАНИЕ**  
на выполнение научно-исследовательской работы

по теме Предсказание региона мира по социально-экономическим показателям  
страны

Студент группы ИУ5-61Б Князев Алексей Михайлович

(Фамилия, имя, отчество)

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)

ИССЛЕДОВАТЕЛЬСКАЯ

Источник тематики (кафедра, предприятие, НИР) КАФЕДРА

График выполнения НИР:

25% к \_\_\_\_\_ нед., 50% к \_\_\_\_\_ нед., 75% к \_\_\_\_\_ нед., 100% к \_\_\_\_\_ нед

**Техническое задание:** решение задачи машинного обучения на основе материалов  
дисциплины

**Оформление научно-исследовательской работы:**

Расчетно-пояснительная записка на 17 листах формата А4.

Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

Дата выдачи задания « \_\_\_\_ » \_\_\_\_\_ 202 \_\_\_\_ г.

Студент

(подпись, дата)

Князев А.М.

(И.О. Фамилия)

Руководитель НИР

(подпись, дата)

Гапанюк Ю.Е.

(И.О. Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

## СОДЕРЖАНИЕ

|                                                           |           |
|-----------------------------------------------------------|-----------|
| <b>ВВЕДЕНИЕ.....</b>                                      | <b>4</b>  |
| <b>1. ПОИСК И ВЫБОР НАБОРА ДАННЫХ.....</b>                | <b>4</b>  |
| <b>2. ЗАГРУЗКА И ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ.....</b>         | <b>6</b>  |
| <b>3. РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ (EDA).....</b>            | <b>7</b>  |
| <b>4. ПРЕДОБРАБОТКА И КОНСТРУИРОВАНИЕ ПРИЗНАКОВ .....</b> | <b>10</b> |
| <b>5. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ.....</b>                      | <b>11</b> |
| <b>6. ВЫБОР МЕТРИК ОЦЕНКИ КАЧЕСТВА.....</b>               | <b>12</b> |
| <b>7. ФОРМИРОВАНИЕ ОБУЧАЮЩЕЙ И ТЕСТОВОЙ ВЫБОРОК .....</b> | <b>13</b> |
| <b>8. БАЗОВЫЕ МОДЕЛИ (BASELINE) .....</b>                 | <b>13</b> |
| <b>9. ПОДБОР ГИПЕРПАРАМЕТРОВ (GRIDSEARCHCV) .....</b>     | <b>14</b> |
| <b>10. СРАВНЕНИЕ МОДЕЛЕЙ .....</b>                        | <b>15</b> |
| <b>11. АНАЛИЗ ЛУЧШЕЙ МОДЕЛИ .....</b>                     | <b>16</b> |
| <b>ЗАКЛЮЧЕНИЕ .....</b>                                   | <b>19</b> |
| <b>СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....</b>             | <b>21</b> |

## **ВВЕДЕНИЕ**

Задача определения географического региона страны по её социально-экономическим характеристикам представляет значительный практический интерес. Международные организации (ООН, МВФ, Всемирный банк), аналитические агентства и исследовательские центры регулярно сталкиваются с необходимостью классификации государств по уровню развития, типу экономики и географическому положению. Ручная разметка требует экспертных знаний и значительных временных затрат, тогда как автоматизированные методы машинного обучения способны решать данную задачу быстро и объективно.

В рамках данной научно-исследовательской работы реализована система многоклассовой классификации стран мира по регионам на основе 25 числовых признаков, охватывающих демографию, экономику, здравоохранение, образование и экологию. Для построения моделей использованы как простые алгоритмы (Logistic Regression, Decision Tree, KNN, SVM, Naive Bayes), так и ансамблевые методы (Random Forest, Gradient Boosting).

Целью работы является построение модели машинного обучения, обеспечивающей максимальное качество классификации стран по регионам мира. В процессе работы выполнен полный цикл: поиск и анализ данных, разведочный анализ, предобработка, отбор признаков, обучение и сравнение моделей, подбор гиперпараметров, разработка веб-приложения.

## **1. ПОИСК И ВЫБОР НАБОРА ДАННЫХ**

Для решения задачи был выбран датасет «Global Country Information Dataset 2023» (Kaggle), содержащий актуальные социально-экономические показатели всех 195 стран мира по состоянию на 2023 год. Датасет охватывает демографическую статистику, экономические показатели, экологические факторы и метрики здравоохранения.

### Обоснование выбора датасета:

1. полнота — охват всех 195 стран мира по единому временному срезу исключает временные искажения;
2. многомерность — 35 признаков из различных сфер жизнедеятельности страны;
3. наличие пропусков — датасет реалистичен и требует применения методов обработки пропущенных значений;
4. наличие как числовых, так и категориальных признаков, что требует полного цикла предобработки;
5. чёткая целевая переменная — регион мира однозначно определяется по названию страны.

**Практическая значимость.** Построенная модель демонстрирует, что географическое положение страны тесно связано с её социально-экономическим профилем. Это подтверждает гипотезу о том, что страны одного региона имеют схожие паттерны развития. Подобные модели применяются в международных организациях для распределения гуманитарной помощи, выявления схожих экологических проблем и планирования медицинской помощи.

Целевая переменная — регион мира (6 классов) — добавлена на основе экспертной разметки по названию страны. Перечень основных признаков датасета приведён в таблице 1.1.

Таблица 1.1 — Описание признаков датасета

| Признак               | Тип      | Описание                                   |
|-----------------------|----------|--------------------------------------------|
| Country               | строка   | Название страны                            |
| Density (P/Km2)       | числовой | Плотность населения (чел/км <sup>2</sup> ) |
| Agricultural Land (%) | числовой | Доля сельскохозяйственных угодий (%)       |
| Land Area (Km2)       | числовой | Площадь страны (км <sup>2</sup> )          |

| Признак                 | Тип      | Описание                                        |
|-------------------------|----------|-------------------------------------------------|
| Birth Rate              | числовой | Рождаемость (на 1000 чел.)                      |
| Co2-Emissions           | числовой | Выбросы CO <sub>2</sub> (тонн)                  |
| GDP                     | числовой | Валовой внутренний продукт (\$)                 |
| Infant mortality        | числовой | Младенческая смертность (на 1000 рождений)      |
| Life expectancy         | числовой | Ожидаемая продолжительность жизни (лет)         |
| Physicians per thousand | числовой | Врачей на 1000 жителей                          |
| Population              | числовой | Численность населения                           |
| Unemployment rate       | числовой | Уровень безработицы (%)                         |
| Urban_population        | числовой | Городское население                             |
| Latitude / Longitude    | числовой | Географические координаты (исключены из модели) |
| Region                  | строка   | Регион мира — целевая переменная                |

## 2. ЗАГРУЗКА И ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ

Загрузка данных выполнена с помощью библиотеки `pandas`. При первичном осмотре датасета (195 строк, 35 столбцов) обнаружено следующее:

1. числовые значения хранятся в строковом формате с символами \$, %, запятыми — требуется очистка;
2. пропущенные значения присутствуют в ряде признаков: Minimum wage — 45 пропусков (23 %), Tax revenue — 26 пропусков (13 %), Armed Forces size — 15 пропусков;

3. нечисловые признаки (Official language, Currency-Code, Capital/Major City и др.) не несут числовой информации для модели и подлежат удалению;

4. целевая переменная Region отсутствует — добавляется на основе экспертной разметки;

5. распределение классов несбалансированно: Африка — 54 страны, Европа — 49, Азия — 41, Северная и Центральная Америка — 23, Океания — 14, Южная Америка — 12.

Итоговый размер датасета после добавления целевой переменной: 195 стран × 36 признаков.

### 3. РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ (EDA)

Для понимания структуры данных и зависимостей между признаками проведён разведочный анализ, включающий построение столбчатых диаграмм, диаграмм рассеяния, ящичных диаграмм и тепловых карт.

На рисунке 1 представлено распределение стран по регионам. Наблюдается заметный дисбаланс: Африка содержит 54 страны, тогда как Южная Америка — лишь 12. Данный факт учитывается при выборе метрик: предпочтение отдаётся таско-усреднению.




Рисунок 1 – Распределение стран по регионам мира

На рисунке 2 показано распределение ВВП по регионам (логарифмическая шкала). Регионы существенно различаются: страны Северной Америки и Европы демонстрируют значительно более высокий уровень ВВП, тогда как африканские страны сосредоточены в нижнем диапазоне значений.




Рисунок 2 – Распределение ВВП по регионам (диаграмма ящика с усами)

На рисунке 3 показана диаграмма рассеяния «Младенческая смертность — Продолжительность жизни» с цветовой разметкой по регионам. Наблюдается чёткое разделение: африканские страны сосредоточены в зоне высокой смертности и низкой продолжительности жизни, европейские — в противоположном углу. Это подтверждает возможность построения классификационных моделей.






Рисунок 3 – Продолжительность жизни vs Младенческая смертность по регионам

На рисунке 4 показан процент пропущенных значений по признакам. Признак Minimum wage имеет наибольшую долю пропусков (23 %) и исключён из анализа. Остальные пропуски заполнены медианой по региону.



Рисунок 4 – Процент пропущенных значений по признакам датасета

На рисунке 5 представлены средние значения ключевых показателей по каждому региону. Чётко прослеживается, что регионы имеют выраженные различия в профилях развития, что создаёт хорошую разделимость классов.




Рисунок 5 – Средние значения ключевых показателей по регионам

#### 4. ПРЕДОБРАБОТКА И КОНСТРУИРОВАНИЕ ПРИЗНАКОВ

По результатам EDA выполнены следующие шаги предобработки:

1. очистка числовых признаков от символов \$, %, запятых и пробелов с помощью регулярных выражений;
2. удаление нечисловых/малоинформативных признаков: Abbreviation, Calling Code, Capital/Major City, Currency-Code, Largest city, Official language, Minimum wage;
3. заполнение пропущенных значений медианой по соответствующему региону; при отсутствии значений во всём регионе — глобальной медианой;
4. кодирование целевой переменной с помощью LabelEncoder: Africa=0, Asia=1, Europe=2, North & Central America=3, Oceania=4, South America=5;
5. масштабирование всех числовых признаков методом StandardScaler (центрирование и нормировка к единичной дисперсии); масштабирование применено только к признакам, целевая переменная не масштабировалась.

Итоговый набор признаков для модели составил 25 числовых

переменных.

## 5. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ

Корреляционный анализ проведён для оценки линейных зависимостей между признаками. На рисунке 6 представлена матрица корреляций Пирсона.




Рисунок 6 – Матрица корреляций числовых признаков

Выявлены следующие значимые зависимости:

- рождаемость (Birth Rate) и фертильность (Fertility Rate):  $r = +0.98$  — признаки практически дублируют друг друга;
- продолжительность жизни (Life expectancy) и младенческая смертность (Infant mortality):  $r = -0.93$  — выраженная обратная зависимость;

- ВВП (GDP) и выбросы CO<sub>2</sub> (Co2-Emissions):  $r = +0.92$  — экономически развитые страны производят больше выбросов;
- продолжительность жизни и рождаемость:  $r = -0.86$  — страны с высокой рождаемостью имеют меньшую продолжительность жизни.

Высокие попарные корреляции между рядом признаков свидетельствуют о мультиколлинеарности. Это не влияет на ансамблевые методы, однако может снижать интерпретируемость линейных моделей. Корреляционный анализ в целом подтверждает содержательные различия между регионами и обоснованность построения классификационных моделей.

## 6. ВЫБОР МЕТРИК ОЦЕНКИ КАЧЕСТВА

Для оценки качества моделей многоклассовой классификации с несбалансированными классами выбраны четыре метрики (таблица 6.1).

Таблица 6.1 — Метрики оценки качества классификации

| Метрика           | Формула                                                                        | Обоснование выбора                                                                    |
|-------------------|--------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| Accuracy          | $(TP + TN) / N$                                                                | Базовая метрика общего качества классификации                                         |
| F1-score (macro)  | $2 \cdot P \cdot R / (P + R)$ ,<br>усреднение по всем классам с равными весами | Штрафует за плохое качество на малых классах (Океания — 14 стран, Южная Америка — 12) |
| Precision (macro) | $TP / (TP + FP)$ ,<br>усреднение по классам                                    | Оценивает долю ложных срабатываний по каждому региону                                 |
| Recall (macro)    | $TP / (TP + FN)$ ,<br>усреднение по классам                                    | Оценивает долю пропущенных стран каждого региона                                      |

Макро-усреднение выбрано намеренно: при weighted-усреднении большой класс (Африка, 54 страны) «заглушает» ошибки на малых классах. Макро-F1 обеспечивает равноправную оценку всех регионов вне зависимости

от их размера.

## 7. ФОРМИРОВАНИЕ ОБУЧАЮЩЕЙ И ТЕСТОВОЙ ВЫБОРОК

Датасет разбит на обучающую и тестовую выборки в соотношении 80/20 с помощью функции `train_test_split` библиотеки `scikit-learn`. Применена стратификация по целевой переменной (параметр `stratify=y`) для сохранения пропорций классов в обеих выборках (таблица 7.1).

Таблица 7.1 — Разбивка данных на выборки

| Выборка   | Назначение                                | Размер (строк) |
|-----------|-------------------------------------------|----------------|
| Обучающая | Обучение моделей и подбор гиперпараметров | 156            |
| Тестовая  | Финальная оценка качества моделей         | 39             |

Параметр `random_state=42` зафиксирован для воспроизводимости результатов. Масштабирование `StandardScaler` обучалось только на обучающей выборке для предотвращения утечки данных (data leakage).

## 8. БАЗОВЫЕ МОДЕЛИ (BASELINE)

На первом этапе обучены семь моделей с параметрами по умолчанию (baseline). Из них две — ансамблевые: Random Forest (бэггинг) и Gradient Boosting (бустинг). Результаты приведены в таблице 8.1.

Таблица 8.1 — Результаты базовых моделей на тестовой выборке

| Модель              | Accuracy | F1 (macro) | Precision | Recall |
|---------------------|----------|------------|-----------|--------|
| Logistic Regression | 0.6923   | 0.6087     | 0.6065    | 0.6225 |
| Decision Tree       | 0.5385   | 0.4715     | 0.4998    | 0.4768 |
| K-Nearest Neighbors | 0.6923   | 0.5701     | 0.5465    | 0.6144 |
| SVM                 | 0.6667   | 0.5534     | 0.5352    | 0.5920 |
| Naive Bayes         | 0.5385   | 0.4879     | 0.4847    | 0.5255 |

| Модель              | Accuracy | F1 (macro) | Precision | Recall |
|---------------------|----------|------------|-----------|--------|
| Random Forest *     | 0.7179   | 0.6905     | 0.7418    | 0.6740 |
| Gradient Boosting * | 0.6667   | 0.5485     | 0.5277    | 0.6129 |

\* — ансамблевые методы

Лучший результат среди базовых моделей показал Random Forest: Accuracy = 0.7179, F1 (macro) = 0.6905. Это свидетельствует о том, что ансамблевые методы лучше справляются с нелинейными зависимостями в данных.

## 9. ПОДБОР ГИПЕРПАРАМЕТРОВ (GRIDSEARCHCV)

Для всех семи моделей выполнен перебор гиперпараметров методом GridSearchCV с 5-кратной кросс-валидацией и метрикой f1\_macro. Оптимальные значения параметров приведены в таблице 9.1.

Таблица 9.1 — Оптимальные гиперпараметры по результатам GridSearchCV

| Модель                 | Параметр                                         | Оптимальное значение                                      |
|------------------------|--------------------------------------------------|-----------------------------------------------------------|
| Logistic Regression    | C, solver                                        | C=10, solver=saga                                         |
| Decision Tree          | max_depth,<br>min_samples_split                  | max_depth=5,<br>min_samples_split=2                       |
| K-Nearest<br>Neighbors | n_neighbors, weights                             | n_neighbors=7,<br>weights=distance                        |
| SVM                    | C, kernel                                        | C=10, kernel=rbf                                          |
| Naive Bayes            | var_smoothing                                    | var_smoothing=1e-7                                        |
| Random Forest          | n_estimators,<br>max_depth,<br>min_samples_split | n_estimators=200,<br>max_depth=10,<br>min_samples_split=2 |
| Gradient Boosting      | n_estimators,<br>learning_rate,                  | n_estimators=200,<br>learning_rate=0.1, max_depth=3       |

| Модель | Параметр  | Оптимальное значение |
|--------|-----------|----------------------|
|        | max_depth |                      |

## 10. СРАВНЕНИЕ МОДЕЛЕЙ

В таблице 10.1 приведены метрики качества настроенных моделей в сравнении с базовыми.

Таблица 10.1 — Сравнение Baseline и Tuned моделей

| Модель              | Версия   | Accuracy | F1<br>macro | Precision | Recall |
|---------------------|----------|----------|-------------|-----------|--------|
| Logistic Regression | Baseline | 0.6923   | 0.6087      | 0.6065    | 0.6225 |
| Logistic Regression | Tuned    | 0.6923   | 0.6087      | 0.6065    | 0.6225 |
| Decision Tree       | Baseline | 0.5385   | 0.4715      | 0.4998    | 0.4768 |
| Decision Tree       | Tuned    | 0.5641   | 0.4885      | 0.5109    | 0.5018 |
| K-Nearest Neighbors | Baseline | 0.6923   | 0.5701      | 0.5465    | 0.6144 |
| K-Nearest Neighbors | Tuned    | 0.6923   | 0.5762      | 0.5577    | 0.6144 |
| SVM                 | Baseline | 0.6667   | 0.5534      | 0.5352    | 0.5920 |
| SVM                 | Tuned    | 0.5897   | 0.4655      | 0.4775    | 0.4601 |
| Naive Bayes         | Baseline | 0.5385   | 0.4879      | 0.4847    | 0.5255 |
| Naive Bayes         | Tuned    | 0.5385   | 0.4879      | 0.4847    | 0.5255 |
| Random Forest<br>*  | Baseline | 0.7179   | 0.6905      | 0.7418    | 0.6740 |

| Модель                 | Версия   | Accuracy | F1<br>macro | Precision | Recall |
|------------------------|----------|----------|-------------|-----------|--------|
| Random Forest<br>*     | Tuned    | 0.7179   | 0.6905      | 0.7418    | 0.6740 |
| Gradient<br>Boosting * | Baseline | 0.6667   | 0.5485      | 0.5277    | 0.6129 |
| Gradient<br>Boosting * | Tuned    | 0.6667   | 0.5485      | 0.5277    | 0.6129 |

\* — ансамблевые методы

Подбор гиперпараметров незначительно улучшил результаты Decision Tree и K-Nearest Neighbors. Для Random Forest и Gradient Boosting параметры по умолчанию уже были близки к оптимальным. Это объясняется малым размером датасета (195 объектов): при небольших данных разброс между разными конфигурациями минимален. На рисунке 7 наглядно показано преимущество ансамблевых методов перед линейными.




Рисунок 7 – Сравнение Accuracy и F1-score: Baseline vs Tuned

## 11. АНАЛИЗ ЛУЧШЕЙ МОДЕЛИ

Лучшей моделью по совокупности метрик признан Random Forest с параметрами `n_estimators=200`, `max_depth=10`, `min_samples_split=2`. Итоговые метрики на тестовой выборке: Accuracy = 0.7179, F1 (macro) = 0.6905, Precision



= 0.7418, Recall = 0.6740.

На рисунке 8 показана матрица ошибок лучшей модели. Наилучшая точность достигнута для Европы и Африки — двух крупнейших классов с наиболее выраженным социально-экономическим профилем. Наибольшее количество ошибок наблюдается при классификации Океании и Южной Америки ввиду малого числа обучающих примеров.




Рисунок 8 – Матрица ошибок классификации (Random Forest)

На рисунке 9 показана важность признаков для Random Forest. Наиболее значимые признаки:

- Life expectancy — продолжительность жизни (наибольший вклад);
- Birth Rate / Fertility Rate — рождаемость и фертильность;
- Infant mortality — младенческая смертность;
- Physicians per thousand — обеспеченность врачами;

– GDP — объём экономики.

Эти признаки напрямую отражают уровень развития страны и её региональную принадлежность, что согласуется с содержательной интерпретацией задачи.




Рисунок 9 – Важность признаков (Random Forest, Tuned)

На рисунке 10 представлена кривая обучения лучшей модели. Разрыв между train и validation F1 невелик, что свидетельствует об отсутствии значительного переобучения. Модель стабилизируется при размере обучающей выборки около 120 объектов.




Рисунок 10 – Кривая обучения Random Forest (F1-macro, cv=5)

На рисунке 11 представлено сравнение всех четырёх метрик для tuned-моделей в виде сгруппированной столбчатой диаграммы.




Рисунок 11 – Сравнение всех метрик для настроенных моделей

## ЗАКЛЮЧЕНИЕ

В ходе работы решена задача многоклассовой классификации — предсказание региона мира по социально-экономическим показателям страны на основе датасета Global Country Information Dataset 2023. Сформулируем

## ОСНОВНЫЕ ВЫВОДЫ.

1. Датасет Global Country Information Dataset 2023 (195 стран, 35 признаков) оказался информативным и пригодным для задачи классификации. После очистки и добавления целевой переменной итоговый набор составил 25 числовых признаков, разбитых на обучающую (156 стран) и тестовую (39 стран) выборки.
2. Разведочный анализ показал, что регионы мира имеют выраженные различия в социально-экономическом профиле. Наибольшую разделимость обеспечивают показатели здравоохранения (продолжительность жизни, младенческая смертность) и демографии (рождаемость, фертильность).
3. Корреляционный анализ выявил сильные линейные зависимости между рядом признаков ( $r > 0.9$ ). Мультиколлинеарность не влияет на ансамблевые методы, однако снижает интерпретируемость линейных моделей.
4. Из семи протестированных алгоритмов ансамблевый метод Random Forest значительно превзошёл все остальные. Базовый Random Forest уже достиг Accuracy = 0.718, F1 (macro) = 0.691.
5. Подбор гиперпараметров методом GridSearchCV (5-кратная кросс-валидация, метрика f1\_macro) не привёл к существенному улучшению большинства моделей ввиду малого размера датасета (195 объектов).
6. Лучшей моделью стал Random Forest: Accuracy = 0.7179, F1 (macro) = 0.6905, Precision = 0.7418, Recall = 0.6740. Наибольшие ошибки наблюдаются для малых регионов (Океания, Южная Америка) из-за недостаточного числа обучающих примеров.
7. – Разработано интерактивное веб-приложение на базе фреймворка Streamlit, позволяющее выбирать модель (Random Forest или Gradient Boosting), настраивать гиперпараметры и в реальном времени наблюдать изменение метрик, матрицы ошибок и важности признаков.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Global Country Information Dataset 2023 [Электронный ресурс] // Kaggle. — URL: <https://www.kaggle.com/datasets/nelgiriyeewithana/countries-of-the-world-2023> (дата обращения: 20.05.2026).
2. Pedregosa F. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830. — URL: <https://scikit-learn.org> (дата обращения: 20.05.2026).
3. Breiman L. Random Forests // Machine Learning. — 2001. — Vol. 45, № 1. — P. 5–32.
4. Friedman J.H. Greedy Function Approximation: A Gradient Boosting Machine // The Annals of Statistics. — 2001. — Vol. 29, № 5. — P. 1189–1232.
5. Streamlit — документация [Электронный ресурс]. — URL: <https://docs.streamlit.io> (дата обращения: 20.05.2026).
6. Pandas — документация [Электронный ресурс]. — URL: <https://pandas.pydata.org/docs> (дата обращения: 20.05.2026).
7. Müller A.C., Guido S. Introduction to Machine Learning with Python. — O'Reilly Media, 2016. — 400 p.